第 9 章　统　计

讲　义

适用：人教版　高一必修 2　|　课时：8 课时

一、知识点讲解

9.1　随机抽样

总体、个体、样本与样本容量

在统计学中，所考察对象的全体称为**总体**，其中每一个考察对象称为**个体**，从总体中抽取的一部分个体称为**样本**，样本中个体的数目称为**样本容量**。
用样本的特征去估计总体的特征，是统计的基本思想。样本容量越大，估计越精确。

简单随机抽样

设总体含有 N 个个体，从中**逐个不放回**地抽取 n 个个体作为样本 $(n \leqslant N)$，如果每次抽取时总体内每个个体被抽到的概率都相等，则这种抽样方法称为**简单随机抽样**。
常用方法：

(1) **抽签法**：将 N 个个体编号并制作号签，搅拌均匀后逐个抽取。

(2) **随机数表法**：将个体编号，利用随机数表依次读取随机数来选取样本。

适用条件：总体容量较小，个体之间无明显差异。

系统抽样（等距抽样）

将总体中的 N 个个体编号，按**等间隔**分成若干段，从第一段中随机确定一个起始编号，再按固定间隔依次抽取。

步骤：

(1) 将总体 N 个个体编号；

(2) 确定分段间隔 $k = \left\lfloor \dfrac{N}{n} \right\rfloor$（若不能整除，先随机剔除多余个体）；

(3) 在第一段 $1 \sim k$ 中随机确定起始编号 l；

(4) 依次抽取编号为 $l,\ l+k,\ l+2k,\ \ldots$ 的个体。

适用条件：总体容量较大，个体之间无明显差异。

分层抽样

当总体由**差异明显**的几部分组成时，先将总体按某种特征分成若干互不交叉的层，再按各层个体数占总体的**比例**独立抽取样本。

设总体分为 m 层，第 i 层有 N_i 个个体，$N = \sum_{i=1}^{m} N_i$，样本容量为 n，则第 i 层应抽取

$$n_i = n \times \frac{N_i}{N} \quad (i = 1, 2, \ldots, m)$$

适用条件：总体由差异明显的几部分组成。

三种抽样方法对比

方法	共同点	各自特点	适用范围
简单随机抽样	每个个体被抽到的概率相等	逐个不放回	总体容量较小
系统抽样		等间隔抽取	总体容量较大且均匀
分层抽样		按比例分层	总体差异明显

9.2 频率分布表与直方图

绘制频率分布直方图的步骤

(1) **求极差**：$R = x_{\max} - x_{\min}$。

(2) **决定组距与组数**：一般取 $5 \sim 12$ 组，组距 $= \left\lceil \dfrac{R}{\text{组数}} \right\rceil$。

(3) **确定分点**：通常取比数据多一位小数，使数据不落在分点上。

(4) **列频率分布表**：统计各组频数 n_i，计算频率 $= \dfrac{n_i}{n}$，以及 $\dfrac{\text{频率}}{\text{组距}}$。

(5) **画直方图**：横轴表示数据，纵轴表示 $\dfrac{\text{频率}}{\text{组距}}$，以组距为底画矩形。

频率分布直方图的关键性质

- 每个小矩形的面积 $=$ 组距 $\times \dfrac{\text{频率}}{\text{组距}} =$ 频率。
- 所有小矩形面积之和 $= 1$。
- 样本容量越大、分组越细，直方图越接近总体的真实分布。

9.3 数字特征

平均数（均值）

设样本数据为 $x_1, x_2, \ldots, x_n$，则**样本均值**为：

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

加权平均数：若数据 $x_1, x_2, \ldots, x_k$ 对应的频数分别为 $f_1, f_2, \ldots, f_k$（$\sum f_i = n$），则

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{k} x_i f_i$$

中位数与众数

中位数：将数据从小到大排列，若 n 为奇数，中位数为第 $\dfrac{n+1}{2}$ 个数据；若 n 为偶数，中位数为第 $\dfrac{n}{2}$ 个与第 $\dfrac{n}{2}+1$ 个数据的平均值。

众数：一组数据中出现次数最多的数据。众数可能不唯一。

方差与标准差

样本方差衡量数据的波动大小：

$$s^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

等价计算公式：

$$s^2 = \frac{1}{n}\sum_{i=1}^{n}x_i^2 - \bar{x}^2$$

标准差为方差的算术平方根：

$$s = \sqrt{s^2}$$

方差（标准差）越大，数据越分散；方差（标准差）越小，数据越集中。

方差的性质

若数据 $x_1, \ldots, x_n$ 的方差为 s^2，则数据 $ax_1+b,\ ax_2+b,\ \ldots,\ ax_n+b$ 的方差为 a^2s^2。即线性变换 $y = ax + b$ 将方差放大 a^2 倍，常数平移不改变方差。

9.4　变量的相关性

散点图与相关关系

对于两个变量 X 和 Y，在平面直角坐标系中画出对应的点 (x_i, y_i)，称为**散点图**。

- **正相关**：X 增大时 Y 也呈增大趋势，散点从左下到右上分布。
- **负相关**：X 增大时 Y 呈减小趋势，散点从左上到右下分布。
- 散点越接近一条直线，线性相关程度越强。

线性回归方程

设 y 关于 x 的线性回归方程为 $\hat{y} = \hat{b}x + \hat{a}$，其中：

$$\hat{b} = \frac{\sum_{i=1}^{n}x_iy_i - n\bar{x}\bar{y}}{\sum_{i=1}^{n}x_i^2 - n\bar{x}^2}, \qquad \hat{a} = \bar{y} - \hat{b}\bar{x}$$

回归直线必过样本中心点 $(\bar{x}, \bar{y})$。

相关系数

相关系数 r 衡量两个变量线性相关的强弱：

$$r=\frac{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i-\bar{x})^2\cdot\sum_{i=1}^{n}(y_i-\bar{y})^2}}$$

- $|r|$ 越接近 1，线性相关越强；
- $|r|$ 越接近 0，线性相关越弱；
- 一般 $|r|>0.75$ 认为线性相关性较强。

二、例题精讲

【例 1】简单随机抽样

某班有 50 名学生，学号为 $01\sim50$，要从中用随机数表法抽取 5 名学生参加体质测试。从随机数表某行某列开始向右读取，依次得到 16, 22, 77, 94, 39, 45, 08，问被抽中的学生学号有哪些？

解：

逐一检查，保留 $01\sim50$ 的编号，跳过超出范围和重复的数：

- 16：在范围内，选中。
- 22：在范围内，选中。
- 77：超出 50，跳过。
- 94：超出 50，跳过。
- 39：在范围内，选中。
- 45：在范围内，选中。
- 08：在范围内，选中。

被抽中的学号为：08, 16, 22, 39, 45。

【例 2】系统抽样

某工厂生产 1000 个零件，编号 $0001\sim1000$，用系统抽样抽取 50 个检测。(1) 求分段间隔；(2) 若起始编号为 0015，写出第 5 个和第 50 个被抽中的编号。

解：

(1) 分段间隔 $k = \dfrac{1000}{50} = 20$。

(2) 第 i 个被抽中的编号为 $15 + (i-1) \times 20$。

- 第 5 个：$15 + 4 \times 20 = 0095$。
- 第 50 个：$15 + 49 \times 20 = 0995$。

【例 3】分层抽样

某校高一 600 人、高二 400 人、高三 500 人，共 1500 人。用分层抽样从全校抽取 60 人进行视力调查，各年级应分别抽取多少人？

解：

抽样比 $= \dfrac{60}{1500} = \dfrac{1}{25}$。

- 高一抽取：$600 \times \dfrac{1}{25} = 24$ 人。
- 高二抽取：$400 \times \dfrac{1}{25} = 16$ 人。
- 高三抽取：$500 \times \dfrac{1}{25} = 20$ 人。

验证：$24 + 16 + 20 = 60$，正确。

【例 4】频率分布直方图

某校抽取 100 名学生测量身高（cm），数据分组如下表。求各组频率和频率/组距，并画出频率分布直方图。

分组	$[150, 155)$	$[155, 160)$	$[160, 165)$	$[165, 170)$
频数	10	30	40	20

解：

样本容量 $n = 100$，组距 $= 5$。

分组	$[150, 155)$	$[155, 160)$	$[160, 165)$	$[165, 170)$
频率	0.10	0.30	0.40	0.20
频率/组距	0.02	0.06	0.08	0.04

频率分布直方图如下：

【例 5】均值与方差的计算

甲、乙两人各射击 5 次，成绩（环数）如下：

- 甲：8, 9, 10, 9, 8
- 乙：7, 10, 10, 9, 9

分别计算均值和方差，判断谁的成绩更稳定。

解：

甲：

$$\bar{x}_{甲} = \frac{8+9+10+9+8}{5} = 8.8$$

$$s^2_{甲} = \frac{(8-8.8)^2+(9-8.8)^2+(10-8.8)^2+(9-8.8)^2+(8-8.8)^2}{5} = \frac{0.64+0.04+1.44+0.04+0.64}{5} = 0.56$$

乙：

$$\bar{x}_{乙} = \frac{7+10+10+9+9}{5} = 9$$

$$s^2_{乙} = \frac{(7-9)^2+(10-9)^2+(10-9)^2+(9-9)^2+(9-9)^2}{5} = \frac{4+1+1+0+0}{5} = 1.2$$

$s^2_{甲} < s^2_{乙}$，甲的成绩更稳定。

【例 6】方差的性质

已知数据 x_1, x_2, x_3, x_4, x_5 的均值为 10，方差为 4。求数据 $3x_1+2$, $3x_2+2$, $3x_3+2$, $3x_4+2$, $3x_5+2$ 的均值和方差。

解：

由线性变换性质 $y_i = ax_i + b$：

$$\text{新均值} = a\bar{x} + b = 3 \times 10 + 2 = 32$$

$$\text{新方差} = a^2 s^2 = 9 \times 4 = 36$$

新数据的均值为 32，方差为 36。

【例 7】回归方程

为研究学习时间 x（小时/天）与数学成绩 y（分）的关系，收集了 5 组数据：

x_i	2	3	4	5	6
y_i	62	68	75	82	88

求 y 关于 x 的线性回归方程，并画出散点图和回归直线。

解：

$$\bar{x} = \frac{2+3+4+5+6}{5} = 4, \qquad \bar{y} = \frac{62+68+75+82+88}{5} = 75$$

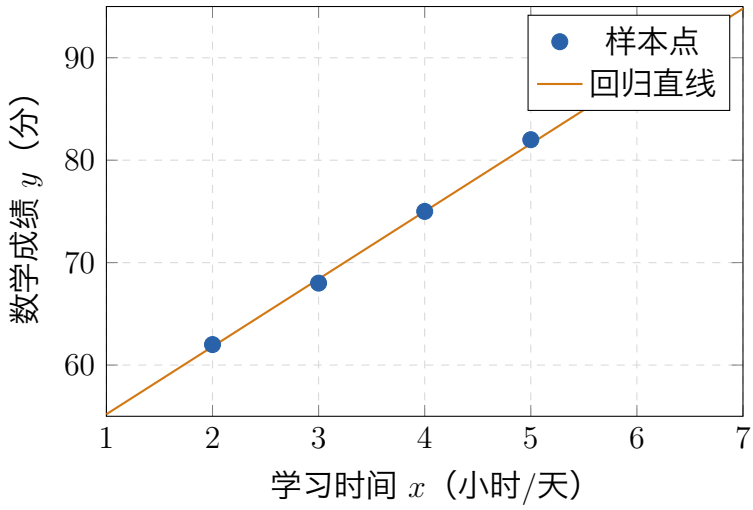
$$\sum x_i y_i = 124 + 204 + 300 + 410 + 528 = 1566$$

$$\sum x_i^2 = 4 + 9 + 16 + 25 + 36 = 90$$

$$\hat{b} = \frac{1566 - 5 \times 4 \times 75}{90 - 5 \times 16} = \frac{66}{10} = 6.6$$

$$\hat{a} = 75 - 6.6 \times 4 = 48.6$$

回归方程：$\hat{y} = 6.6x + 48.6$



【例 8】频率分布直方图中估计均值

根据例 4 中的频率分布直方图，估计这 100 名学生身高的平均值。

解：

用各组的**组中值**乘以频率再求和：

各组组中值：152.5，157.5，162.5，167.5。

$$\bar{x} \approx 152.5 \times 0.10 + 157.5 \times 0.30 + 162.5 \times 0.40 + 167.5 \times 0.20$$
$$= 15.25 + 47.25 + 65.00 + 33.50 = 161(\text{cm})$$

估计平均身高约为 161 cm。

【例 9】综合：抽样与统计推断

某市有高中生 24000 人，其中高一 8000 人、高二 7000 人、高三 9000 人。计划抽取 1200 人调查视力。(1) 应采用什么抽样方法？(2) 各年级各抽多少人？(3) 若调查后高一近视率为 40%，高二为 55%，高三为 70%，估计全市高中生近视率。

解：

(1) 不同年级的近视率可能有明显差异，应采用**分层抽样**。

(2) 抽样比 $= \dfrac{1200}{24000} = \dfrac{1}{20}$。

- 高一：$8000 \times \dfrac{1}{20} = 400$ 人。
- 高二：$7000 \times \dfrac{1}{20} = 350$ 人。
- 高三：$9000 \times \dfrac{1}{20} = 450$ 人。

(3) 综合近视率（加权平均）：

$$\bar{p} = \frac{400 \times 0.40 + 350 \times 0.55 + 450 \times 0.70}{1200} = \frac{160 + 192.5 + 315}{1200} = \frac{667.5}{1200} \approx 55.6\%$$

【例 10】综合统计计算

40 名学生数学成绩（分）如下，求均值、中位数和标准差。

$$\begin{array}{cccccccccc} 85, & 92, & 78, & 88, & 76, & 95, & 82, & 71, & 89, & 90 \\ 73, & 86, & 91, & 80, & 77, & 93, & 84, & 69, & 87, & 74 \\ 96, & 81, & 79, & 90, & 83, & 70, & 88, & 94, & 75, & 82 \\ 85, & 78, & 92, & 86, & 68, & 89, & 80, & 73, & 91, & 87 \end{array}$$

解：

排序后第 20 个和第 21 个数据为 84 和 85。

中位数 $= \dfrac{84 + 85}{2} = 84.5$。

均值：$\bar{x} = \dfrac{85 + 92 + \cdots + 87}{40} = \dfrac{3300}{40} = 82.5$。

方差：$\sum x_i^2 = 274708$

$$s^2 = \frac{274708}{40} - 82.5^2 = 6867.7 - 6806.25 = 61.45$$

标准差：$s = \sqrt{61.45} \approx 7.84$。

三、应用题

【应用 1】灯泡质量检测

某工厂生产 5000 个灯泡，质检员用系统抽样抽取 100 个检测，发现 4 个不合格。(1) 估计这批灯泡中不合格品的数量。(2) 若出厂要求不合格率不超过 5%，能否出厂？

解：

(1) 样本不合格率 $= \dfrac{4}{100} = 4\%$。估计不合格品数量 $= 5000 \times 4\% = 200$ 个。

(2) $4\% < 5\%$，符合标准，可以出厂。

【应用 2】电商平台满意度调查

某电商平台调查 200 名用户的满意度评分（$1 \sim 5$ 分），结果如下：

评分	1	2	3	4	5
频数	10	20	50	80	40

(1) 计算评分的均值和方差。(2) 画出频率分布直方图。

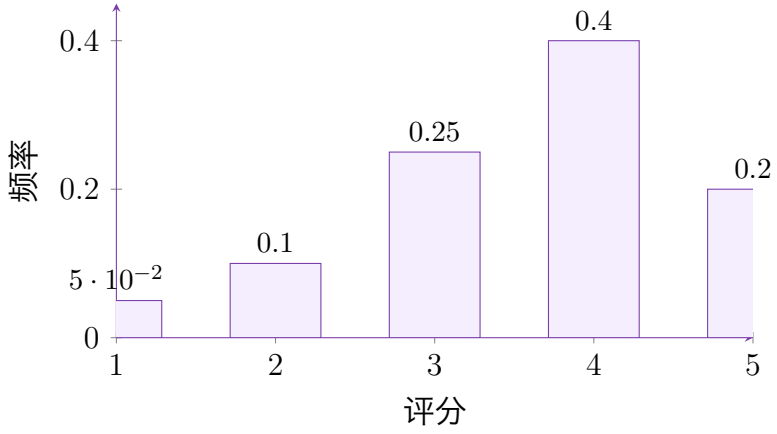
解：

(1)

$$\bar{x} = \frac{1\times 10 + 2\times 20 + 3\times 50 + 4\times 80 + 5\times 40}{200} = \frac{720}{200} = 3.6$$

$$s^2 = \frac{1^2\times 10 + 2^2\times 20 + 3^2\times 50 + 4^2\times 80 + 5^2\times 40}{200} - 3.6^2 = 14.1 - 12.96 = 1.14$$

(2) 频率分布直方图：



【应用 3】气温与冰淇淋销量回归

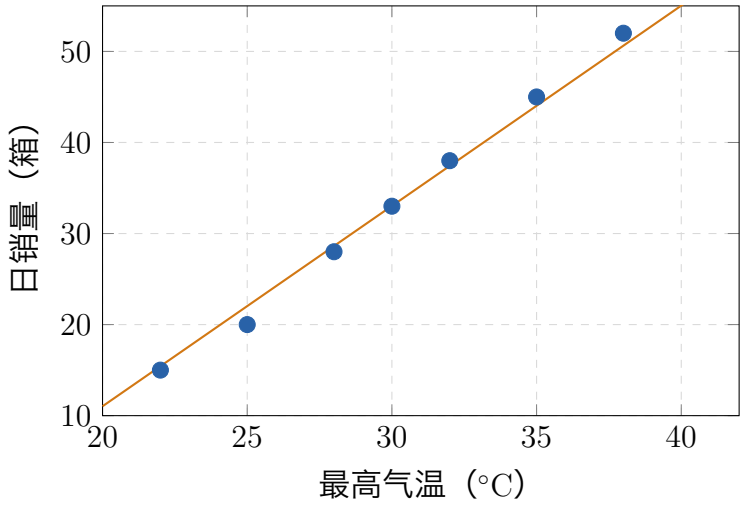
气象站记录 7 天最高气温 x（°C）与冰淇淋日销量 y（箱）：

x	22	25	28	30	32	35	38
y	15	20	28	33	38	45	52

(1) 画散点图，判断相关性。(2) 求回归方程。(3) 预测 $40°C$ 时的日销量。

解：

(1) 散点图显示 x 与 y 呈**正相关**。



(2) $\bar{x}=30$，$\bar{y}=33$，$\sum x_iy_i=7339$，$\sum x_i^2=6486$。

$$\hat{b}=\frac{7339-7\times30\times33}{6486-7\times900}=\frac{409}{186}\approx2.199$$
$$\hat{a}=33-2.199\times30\approx-32.97$$

回归方程：$\hat{y}=2.20x-32.97$

(3) 当 $x=40$ 时：$\hat{y}=2.20\times40-32.97=55.03\approx55$（箱）。

四、课堂练习

1. 某校高一 400 人、高二 350 人、高三 450 人，用分层抽样抽取 120 人，各年级各抽多少人？

2. 数据 2，4，6，8，10 的均值和方差各是多少？

3. 已知数据 x_1,x_2,x_3,x_4 的均值为 5，方差为 3。求 $2x_1-1$，$2x_2-1$，$2x_3-1$，$2x_4-1$ 的均值和方差。

4. 频率分布直方图中，$[20,30)$ 的面积为 0.3，$[30,40)$ 的面积为 0.5，$[40,50)$ 的面积为 0.2。样本容量 200，求数据落在 $[30,50)$ 的人数。

5. 已知 $\bar{x}=3$，$\bar{y}=5$，$\sum x_iy_i=90$，$\sum x_i^2=55$，$n=10$。求回归方程 $\hat{y}=\hat{b}x+\hat{a}$。

6. 甲组数据 $2,4,6,8,10$，乙组数据 $4,5,6,7,8$。比较两组方差，哪组更稳定？

参考答案

1. 总人数 1200，高一 40 人，高二 35 人，高三 45 人。

2. $\bar{x}=6$，$s^2=\dfrac{16+4+0+4+16}{5}=8$。

3. 新均值 $=2\times5-1=9$，新方差 $=4\times3=12$。

4. $[30,50)$ 频率 $=0.5+0.2=0.7$，人数 $=200\times0.7=140$ 人。

5. $\hat{b}=\dfrac{90-10\times3\times5}{55-10\times9}=\dfrac{-60}{-35}=\dfrac{12}{7}$，$\hat{a}=5-\dfrac{12}{7}\times3=-\dfrac{1}{7}$。
   回归方程：$\hat{y}=\dfrac{12}{7}x-\dfrac{1}{7}$。

6. 甲 $s^2=8$，乙 $s^2=2$。乙组更稳定。